

# Modelos AutoRegresivos de Media Móvil (ARMA)

Randall Romero Aguilar, PhD  
[randall.romero@ucr.ac.cr](mailto:randall.romero@ucr.ac.cr)

EC4301 - Macroeconometría  
I Semestre 2020

Última actualización: 17 de mayo de 2020




# Tabla de contenidos

1. Introducción
2. Proceso de media móvil  $MA(q)$
3. Proceso autorregresivo  $AR(p)$
4. Proceso autorregresivo de media móvil  $ARMA(p,q)$
5. Estimación de modelos ARMA
6. Pronósticos con modelos ARMA

# 1. Introducción

# ¿Qué es una serie de tiempo?

Una serie de tiempo  $\{y_t\}_{t=1}^T$  es una realización de un proceso estocástico.



# ¿Qué nos gustaría hacer con esta serie de tiempo?

- Imaginemos a la serie de tiempo como la parte de un proceso estocástico para la cual ya tenemos las realizaciones del proceso (un valor por período)

$$\underbrace{y_1, y_2, \dots, y_T}_{\text{datos observados}}, \underbrace{y_{T+1}, y_{T+2}, \dots}_{\text{futuro}}$$

- Nos gustaría saber **la distribución condicional**

$$\mathbb{P}[y_{T+j} \leq x \mid y_1, \dots, y_T]$$

- Esto nos permitiría utilizar nuestra serie de tiempo para pronosticar valores futuros de la serie, así como precisar su variabilidad:

$$\begin{aligned}\mathbb{E}_T[y_{T+j}] &\equiv \mathbb{E}[y_{T+j} \mid y_1, \dots, y_T] \\ \text{Var}_T[y_{T+j}] &\equiv \text{Var}[y_{T+j} \mid y_1, \dots, y_T]\end{aligned}$$

- ▶ En la práctica, puede ser que nunca conozcamos el verdadero **proceso generador de datos (PGD)** (el proceso estocástico del cual fueron obtenidos los valores de nuestra serie de tiempo).
- ▶ Nuestra tarea es desarrollar **modelos** que capturen la esencia del verdadero PGD.
- ▶ Las ecuaciones en diferencia estocásticas son una manera muy conveniente de modelar procesos económicos dinámicos.

Ejemplo 1:

Controlando la oferta de dinero

- Suponga que la meta de oferta monetaria  $M^*$  del banco central crece 100g% por año:

$$M_t^* = (1 + g)M_{t-1}^*$$

o en términos logarítmicos, con  $m^* \equiv \log(M^*)$

$$m_t^* = \log(1 + g) + m_{t-1}^*$$

$$m_t^* \approx g + m_{t-1}^*$$

- Para una condición inicial  $m_0^*$  dada, la solución es:

$$m_t^* = gt + m_0^*$$



- ▶ La cantidad efectiva de dinero  $m_t$  puede diferir de la meta  $m_t^*$ .
- ▶ El banco central intenta cerrar una proporción  $\rho$  de la brecha entre la meta y la cantidad efectiva del período anterior. El cambio en la oferta de dinero es:

$$\Delta m_t = \underbrace{\rho (m_{t-1}^* - m_{t-1})}_{\text{política monetaria}} + \underbrace{\epsilon_t}_{\text{perturbación}}$$

- ▶ por lo que la oferta de dinero es

$$\begin{aligned} m_t &= \rho m_{t-1}^* + (1 - \rho)m_{t-1} + \epsilon_t \\ &= \rho g(t - 1) + \rho m_0^* + (1 - \rho)m_{t-1} + \epsilon_t \\ &= \underbrace{\rho(m_0^* - g)}_{\text{intercepto}} + \underbrace{(\rho g)t}_{\text{tendencia}} + \underbrace{(1 - \rho)m_{t-1}}_{\text{autorregresivo}} + \underbrace{\epsilon_t}_{\text{shock}} \end{aligned}$$

$$m_t = \underbrace{\rho(m_0^* - g)}_{\text{intercepto}} + \underbrace{(\rho g)t}_{\text{tendencia}} + \underbrace{(1 - \rho)m_{t-1}}_{\text{autorregresivo}} + \underbrace{\epsilon_t}_{\text{shock}}$$

- ▶ Aunque la oferta monetaria es una variable continua, nuestro modelo es una ecuación en diferencia (discreta).
- ▶ Como las perturbaciones  $\{\epsilon_t\}$  son aleatorias, la oferta de dinero es estocástica.
- ▶ Si supiéramos la distribución de  $\{\epsilon_t\}$ , podríamos calcular la distribución de cada elemento de  $\{m_t\}$ , porque está determinada completamente por los parámetros de la ecuación y por la secuencia  $\{\epsilon_t\}$ .
- ▶ Habiendo observado las primeras  $T$  observaciones de la serie  $\{m_t\}$ , podríamos pronosticar futuros valores. Por ejemplo:

$$m_{T+1} = \rho(gT + m_0^*) + (1 - \rho)m_T + \epsilon_{T+1}$$

$$\Rightarrow \mathbb{E}_T[m_{T+1}] = \rho(gT + m_0^*) + (1 - \rho)m_T$$

# Ruido blanco y el modelo clásico de regresión lineal

- ▶ En el MCRL se asume que

$$y_t = x_t' \beta + \epsilon_t$$

donde para todas las observaciones  $t = 1, 2, \dots, T$  el término de error cumple que:

$$\mathbb{E}[\epsilon_t] = 0 \quad (\text{media cero})$$

$$\text{Var}[\epsilon_t] = \sigma^2 \quad (\text{no hay heteroscedasticidad})$$

$$\mathbb{E}[\epsilon_t \epsilon_\tau] = 0 \quad \text{si } t \neq \tau \quad (\text{no hay autocorrelación})$$

- ▶ Es decir, el MCRL aplicado a series de tiempo asume que el error es un proceso de ruido blanco.
- ▶ Sin embargo, en la práctica rara vez se satisface ese supuesto cuando se ajusta un modelo de regresión lineal a datos de series de tiempo.

Ejemplo 2:

## Estimando la demanda de dinero



bccr



---

demandadinero.ipynb


Consideremos la demanda de dinero en Costa Rica

$$\log(M_t) = \beta_0 + \beta_1 \log(q_t) + \beta_2 \log(p_t) + \beta_3 \log(i_t) + \epsilon_t$$

la cual estimamos con datos mensuales (1991m01 a 2020m01) del medio circulante  $M_t$ , el IMAE  $q_t$ , el IPC  $p_t$ , y la tasa básica pasiva  $i_t$ .

	coef	std err	t	P>  t	[0.025	0.975]
<b>Intercept</b>	5.5080	0.227	24.251	0.000	5.061	5.955
<b>IMAE</b>	1.1300	0.059	19.143	0.000	1.014	1.246
<b>IPC</b>	0.9463	0.021	45.664	0.000	0.905	0.987
<b>Tbasica</b>	-0.2409	0.018	-13.641	0.000	-0.276	-0.206

No obstante, los residuos de la regresión no parecen ruido blanco.



- ▶ Conocer el valor de un residuo puede ayudar a pronosticar el siguiente.
- ▶ Aún así, notemos que para pronosticar el valor del M1 en 2020m02, necesitaríamos pronosticar los valores de las demás variables.

# En esta clase

- ▶ En esta clase aprenderemos a modelar series de tiempo en función de:
  - ▶ sus valores rezagados (procesos autorregresivos)
  - ▶ valores rezagados de un ruido blanco (procesos de media móvil)
- ▶ Primero estudiamos las propiedades teóricas de procesos estocásticos.
- ▶ Luego tratamos de identificar el PGD de nuestra serie a partir de sus estadísticos muestrales, comparándolos con los estadísticos de los procesos del punto anterior.
- ▶ Finalmente, utilizamos nuestro modelo estimado para
  - ▶ análisis de escenarios: ¿qué pasaría con la serie de tiempo si recibe una perturbación estocástica de cierta magnitud (función impulso respuesta)
  - ▶ pronósticos: ¿qué valores esperamos ver en el futuro para esta serie de tiempo?

# Modelos que estudiaremos

## Ruido blanco

Es una secuencia  $\{\epsilon_t\}$  cuyos elementos satisfacen,

$$\mathbb{E}(\epsilon_t) = 0$$

$$\mathbb{E}(\epsilon_t^2) = \sigma^2$$

$$\mathbb{E}(\epsilon_t \epsilon_\tau) = 0 \quad \text{for } t \neq \tau$$

## Proceso media móvil

Sea  $\{\epsilon_t\}$  ruido blanco; el proceso estocástico

$$y_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

con  $\theta_q \neq 0$  es llamado un proceso MA(q).

## Proceso autorregresivo

Sea  $\{\epsilon_t\}$  ruido blanco; el proceso estocástico

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \epsilon_t$$

con  $\phi_p \neq 0$  es llamado un proceso AR(p).

## Autorregresivo media móvil

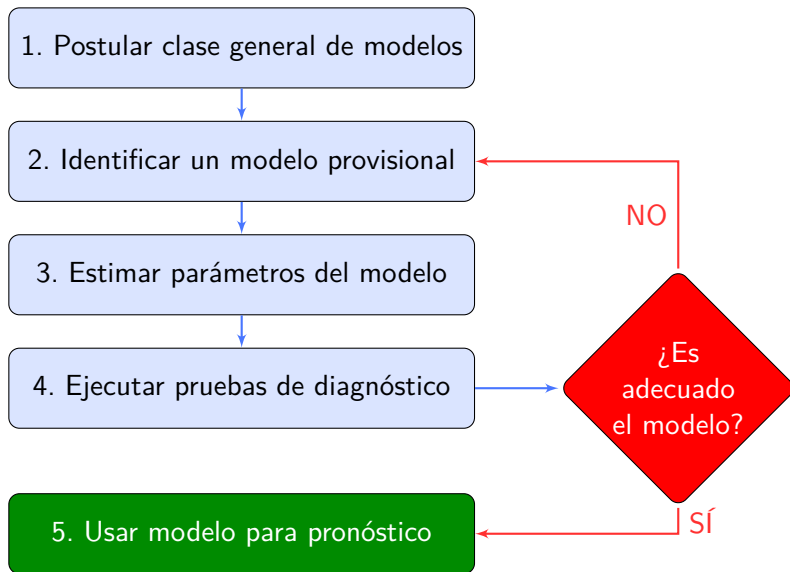
Sea  $\{\epsilon_t\}$  ruido blanco; el proceso estocástico

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \dots + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

es llamado proceso ARMA(p,q).



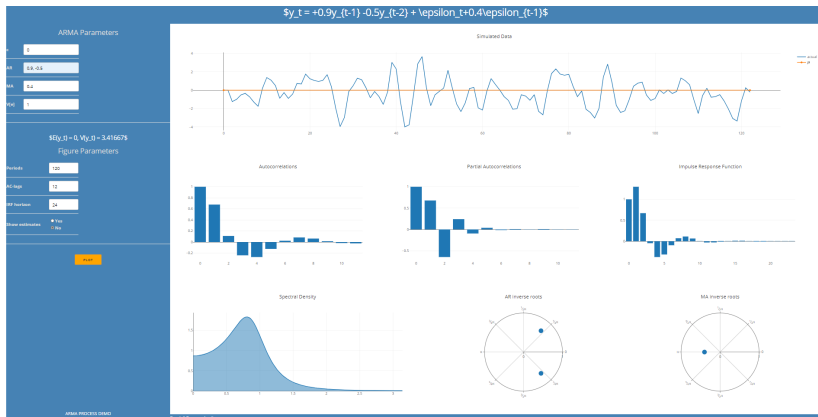
# La metodología Box-Jenkins



# Acerca de los ejemplos

- ▶ En esta clase veremos ilustraciones de distintos procesos AR, MA, y ARMA.
- ▶ Usted puede reproducirlas (y estudiar más casos específicos de estos procesos) con el paquete `macrodemos` que escribí en Python para este tema.
- ▶ Para instalarlo: `pip install macrodemos`
- ▶ Para ejecutarlo:

```
1 from macrodemos import ARMA_demo
2 ARMA_demo()
```



## 2. Proceso de media móvil $MA(q)$

# Proceso media móvil de primer orden: MA(1)

- ▶ Sea  $\{\epsilon_t\}_{t=-\infty}^{\infty}$  un proceso ruido blanco.
- ▶ Se define el proceso MA(1) como:

$$\begin{aligned}y_t &= \mu + \epsilon_t + \theta \epsilon_{t-1} \\ &= \mu + (1 + \theta L)\epsilon_t\end{aligned}$$

- ▶ Su valor esperado es:

$$\begin{aligned}\mathbb{E}[y_t] &= \mu + \mathbb{E}[\epsilon_t] + \theta \mathbb{E}[\epsilon_{t-1}] \\ &= \mu + 0 + 0\theta \\ &= \mu\end{aligned}$$

► Su varianza es

$$\begin{aligned}\text{Var}[y_t] &\equiv \mathbb{E} [(y_t - \mathbb{E}[y_t])^2] \\ &= \mathbb{E} [(y_t - \mu)^2] \\ &= \mathbb{E} [(\epsilon_t + \theta\epsilon_{t-1})^2] \\ &= \mathbb{E} [\epsilon_t^2 + 2\theta\epsilon_t\epsilon_{t-1} + \theta^2\epsilon_{t-1}^2] \\ &= \mathbb{E} [\epsilon_t^2] + 2\theta \mathbb{E} [\epsilon_t\epsilon_{t-1}] + \theta^2 \mathbb{E} [\epsilon_{t-1}^2] \\ &= \sigma^2 + 2\theta \times 0 + \theta^2\sigma^2 \\ &= (1 + \theta^2)\sigma^2\end{aligned}$$


- Su autocovarianza  $j$ , para  $j \geq 1$ , es

$$\begin{aligned}\text{Cov}[y_t, y_{t-j}] &= \mathbb{E}[(y_t - \mu)(y_{t-j} - \mu)] \\&= \mathbb{E}[(\epsilon_t + \theta\epsilon_{t-1})(\epsilon_{t-j} + \theta\epsilon_{t-j-1})] \\&= \mathbb{E}[\epsilon_t\epsilon_{t-j} + \theta\epsilon_t\epsilon_{t-j-1} + \theta\epsilon_{t-1}\epsilon_{t-j} + \theta^2\epsilon_{t-1}\epsilon_{t-j-1}] \\&= 0 + \theta \times 0 + \theta \mathbb{E}[\epsilon_{t-1}\epsilon_{t-j}] + \theta^2 \times 0 \\&= \theta \mathbb{E}[\epsilon_{t-1}\epsilon_{t-j}] = \begin{cases} \theta\sigma^2 & , \text{ si } j = 1 \\ 0 & , \text{ si } j > 1 \end{cases}\end{aligned}$$

- Por lo tanto, su función de autocorrelación es

$$\rho_j = \begin{cases} \frac{\theta}{1+\theta^2} & , \text{ si } j = 1 \\ 0 & , \text{ si } j > 1 \end{cases}$$

- Notemos que la función de autocorrelación de  $y_t = \mu + \epsilon_t + \theta\epsilon_{t-1}$  es la misma que para el proceso  $z_t = \mu + \epsilon_t + \frac{1}{\theta}\epsilon_{t-1}$





- Resumiendo los resultados que hemos obtenido

$$\mathbb{E}[y_t] = \mu$$

$$\text{Var}[y_t] = (1 + \theta^2)\sigma^2$$


$$\text{Cov}[y_t, y_{t-j}] = \begin{cases} \theta\sigma^2 & , \text{ si } j = 1 \\ 0 & , \text{ si } j > 1 \end{cases}$$

vemos que ninguno de estos momentos depende del tiempo  $t$ , por lo que el proceso MA(1) siempre es covarianza-estacionario.


Ejemplo 3:  
 $MA(1)$

$$y_t = \epsilon_t + 0.8\epsilon_{t-1}$$

Realización




Autocorrelación



$$y_t = \epsilon_t - 0.8\epsilon_{t-1}$$

Realización



Autocorrelación



# Invertibilidad de un proceso MA(1)

- Supongamos que  $\mu = 0$ , con lo que el proceso es

$$y_t = \epsilon_t + \theta\epsilon_{t-1} = (1 + \theta L)\epsilon_t$$

- Siempre que  $|\theta| < 1$  podemos invertir el polinomio  $(1 + \theta L)$ :

$$(1 + \theta L)^{-1} = (1 - \theta L + \theta^2 L^2 - \theta^3 L^3 + \dots)$$

- con lo que

$$\begin{aligned}\epsilon_t &= (1 + \theta L)^{-1} y_t \\ &= (1 - \theta L + \theta^2 L^2 - \theta^3 L^3 + \dots) y_t \\ &= y_t - \theta y_{t-1} + \theta^2 y_{t-2} - \theta^3 y_{t-3} + \dots\end{aligned}$$

$$\Rightarrow y_t = \epsilon_t + \theta y_{t-1} - \theta^2 y_{t-2} + \theta^3 y_{t-3} - \dots$$

- Es decir, podemos representar el proceso MA(1) como un proceso AR( $\infty$ ).

- ▶ Recordemos que si bien un proceso MA(1) con parámetro  $\theta$  tiene exactamente la misma función de autocorrelación que un proceso con parámetro  $\frac{1}{\theta}$ , solo uno de ellos puede ser invertible, porque si  $|\theta| < 1$ , entonces  $|\frac{1}{\theta}| > 1$ .
- ▶ Para ciertos métodos de estimación, sólo será posible estimar el modelo MA(1) si es invertible.
- ▶ Por ello, para modelos no invertibles se suele cambiar el parámetro por su recíproco.

# El proceso MA(q)

- ▶ Es fácil extender el proceso MA(1) para incluir más rezagos.
- ▶ El proceso MA(q) es

$$\begin{aligned}y_t &= \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q} \\&= \mu + (1 + \theta_1 L + \cdots + \theta_q L^q) \epsilon_t \\&= \mu + \Theta(L) \epsilon_t\end{aligned}$$

con  $\epsilon_t$  ruido blanco.

- ▶ Su valor esperado es

$$\begin{aligned}\mathbb{E}(y_t) &= \mathbb{E}(\mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}) \\&= \mu + \mathbb{E}(\epsilon_t) + \theta_1 \mathbb{E}(\epsilon_{t-1}) + \cdots + \theta_q \mathbb{E}(\epsilon_{t-q}) \\&= \mu\end{aligned}$$

- Su varianza es

$$\begin{aligned}\text{Var}[y_t] &= \mathbb{E} [(y_t - \mu)^2] \\ &= \mathbb{E} [(\epsilon_t + \theta_1\epsilon_{t-1} + \cdots + \theta_q\epsilon_{t-q})^2] \\ &= \sigma^2 + \theta_1^2\sigma^2 + \cdots + \theta_q^2\sigma^2 \\ &= (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma^2\end{aligned}$$

- mientras que su autocovarianza es

$$\gamma_j = \begin{cases} (\theta_j + \theta_{j+1}\theta_1 + \theta_{j+2}\theta_2 + \cdots + \theta_q\theta_{q-j})\sigma^2 & \text{si } j = 1, 2, \dots, q \\ 0 & \text{para } j > q. \end{cases}$$

- es decir, una característica distintiva de un proceso MA(q) es que todas sus autocorrelaciones para rezagos mayores a  $q$  son cero.

# Invertibilidad de un proceso MA(q)

- ▶ El proceso MA(q)

$$y_t = \mu + \Theta(L)\epsilon_t$$

será invertible si y solo si las raíces del polinomio  $\Theta(z)$  están todas fuera del círculo unitario.

- ▶ En ese caso, el proceso se puede representar por

$$\epsilon_t = \Theta^{-1}(L)(y_t - \mu)$$

lo cual corresponde a un proceso AR( $\infty$ ).



# Función impulso respuesta de un proceso MA(q)

- ▶ La función de impulso respuesta está definida por

$$\Psi(j) = \frac{\partial y_{t+j}}{\partial \epsilon_t}$$

es decir, nos dice cuánto cambia  $y$  luego de  $j$  períodos ante una perturbación.

- ▶ Para series estacionarias, podemos escribir

$$\Psi(j) = \frac{\partial y_t}{\partial \epsilon_{t-j}}$$

- ▶ Pero como  $y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$  es fácil ver que

$$\Psi(j) = \theta_j$$


es decir, la función de impulso respuesta es idéntica a los coeficientes del proceso MA(q).

Ejemplo 4:


$MA(2)$  y  $MA(4)$

$$y_t = \epsilon_t + 0.5\epsilon_{t-1} + 0.5\epsilon_{t-2}$$


Realización




Función impulso respuesta



Autocorrelación




Raíces de  $z^2 + 0.5z + 0.5$




$$y_t = \epsilon_t - 0.6\epsilon_{t-1} + 0.3\epsilon_{t-2} - 0.5\epsilon_{t-3} + 0.5\epsilon_{t-4}$$


Realización




Función impulso respuesta



Autocorrelación



Raíces de  $z^4 - 0.6z^3 + 0.3z^2 - 0.5z + 0.5$



# Proceso media móvil de orden infinito: $MA(\infty)$

- Definimos el proceso  $MA(\infty)$  como

$$y_t = \mu + \psi_0 \epsilon_t + \psi_1 \epsilon_{t-1} + \psi_2 \epsilon_{t-2} + \dots$$

- Su media es

$$\mathbb{E}[y_t] = \mu$$

- Su varianza es

$$\gamma_0 = (\psi_0^2 + \psi_1^2 + \psi_2^2 + \dots) \sigma^2$$

la cual es finita siempre y cuando

$$\sum_{j=0}^{\infty} \psi_j^2 < \infty$$

### 3. Proceso autorregresivo $AR(p)$

# Proceso autorregresivo de primer orden: AR(1)

- ▶ Sea  $\{\epsilon_t\}_{t=-\infty}^{\infty}$  un proceso ruido blanco.
- ▶ Se define el proceso AR(1) como:

$$\begin{aligned}y_t &= c + \phi y_{t-1} + \epsilon_t \\y_t - \phi y_{t-1} &= c + \epsilon_t \\(1 - \phi L)y_t &= c + \epsilon_t\end{aligned}$$

- ▶ Siempre que  $|\phi| < 1$  podemos invertir el término  $(1 - \phi L)$

$$\begin{aligned}y_t &= (1 - \phi L)^{-1} (c + \epsilon_t) \\&= (1 - \phi L)^{-1} c + (1 - \phi L)^{-1} \epsilon_t \\&= \frac{c}{1 - \phi} + (1 + \phi L + \phi^2 L^2 + \dots) \epsilon_t \\&= \frac{c}{1 - \phi} + \epsilon_t + \phi \epsilon_{t-1} + \phi^2 \epsilon_{t-2} + \dots\end{aligned}$$

- Vemos por tanto que si  $|\phi| < 1$  el proceso AR(1) puede escribirse como el proceso MA( $\infty$ )

$$y_t = \frac{c}{1 - \phi} + \epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots$$

- Por lo que su valor esperado es:

$$\mathbb{E}[y_t] \equiv \mu = \frac{c}{1 - \phi}$$

- y su varianza es

$$\begin{aligned}\text{Var}[y_t] \equiv \gamma_0 &= (1 + \phi^2 + \phi^4 + \phi^6 + \dots) \sigma^2 \\ &= \frac{\sigma^2}{1 - \phi^2}\end{aligned}$$



- ▶ La representación  $MA(\infty)$  nos muestra que  $y_t$  depende de la perturbación presente  $\epsilon_t$  y de **todas las pasadas**  $\epsilon_{t-1}, \epsilon_{t-2}, \dots$ , pero no depende de **ninguna de las perturbaciones futuras**  $\epsilon_{t+1}, \epsilon_{t+2}, \dots$ .
- ▶ Por ello, la covarianza de  $y_t$  con cualquier perturbación posterior  $\epsilon_{t+k}$  (con  $k > 0$ ) es cero.

- ▶ Sabiendo que un proceso AR(1) es estacionario si  $|\phi| < 1$ , es fácil obtener sus momentos sin necesidad de obtener su representación MA( $\infty$ ).
- ▶ En el caso de la media:

$$\begin{aligned}
 y_t &= c + \phi y_{t-1} + \epsilon_t \\
 \mathbb{E}[y_t] &= c + \phi \mathbb{E}[y_{t-1}] + \mathbb{E}[\epsilon_t] \\
 \mu &= c + \phi \mu + 0 \\
 \Rightarrow \mu &= \frac{c}{1 - \phi}
 \end{aligned}$$

- ▶ Restando la tercera línea de la primera, vemos que el proceso puede escribirse como un AR(1) para la **desviación respecto a la media** sin la constante:

$$\underset{\tilde{y}_t}{y_t} - \mu = \phi \left( \underset{\tilde{y}_{t-1}}{y_{t-1}} - \mu \right) + \epsilon_t$$

- Para obtener su varianza elevamos al cuadrado la expresión anterior y tomamos su valor esperado

$$\begin{aligned}\mathbb{E}(\tilde{y}_t^2) &= \mathbb{E}\left[(\phi\tilde{y}_{t-1} + \epsilon_t)^2\right] \\ \gamma_0 &= \mathbb{E}\left[\phi^2\tilde{y}_{t-1}^2 + 2\phi\tilde{y}_{t-1}\epsilon_t + \epsilon_t^2\right] \\ &= \phi^2\gamma_0 + 2 \times 0 + \sigma^2 \\ \Rightarrow \gamma_0 &= \frac{\sigma^2}{1 - \phi^2}\end{aligned}$$

- Para obtener su autocovarianza  $\gamma_j$ , para  $j \geq 1$ , escribimos

$$\tilde{y}_t = \phi \tilde{y}_{t-1} + \epsilon_t$$

multiplicamos ambos lados por  $\tilde{y}_{t-j}$  y tomamos esperanza

$$\mathbb{E} [\tilde{y}_t \tilde{y}_{t-j}] = \mathbb{E} [\phi \tilde{y}_{t-1} \tilde{y}_{t-j} + \tilde{y}_{t-j} \epsilon_t]$$

$$\gamma_j = \phi \gamma_{j-1}$$

- Vemos que la función de autocorrelación es la solución de una ecuación en diferencia homogénea de primer orden, cuya solución es

$$\gamma_j = \phi^j \gamma_0$$

- Resumiendo los resultados que hemos obtenido

$$\mathbb{E}[y_t] = \mu = \frac{c}{1 - \phi}$$

$$\text{Var}[y_t] = \gamma_0 = \frac{\sigma^2}{1 - \phi^2}$$

$$\text{Cov}[y_t, y_{t-j}] = \gamma_j = \phi^j \gamma_0$$

$$\rho_j = \phi^j$$

vemos que ninguno de estos momentos depende del tiempo  $t$ , por lo que el proceso AR(1) es covarianza-estacionario siempre y cuando  $|\phi| < 1$ .

- A partir de la representación  $MA(\infty)$  del proceso  $AR(1)$  con  $|\phi| < 1$

$$y_t = \mu + \epsilon_t + \phi\epsilon_{t-1} + \phi^2\epsilon_{t-2} + \dots$$

es fácil observar que su función de impulso respuesta


$$\Psi(j) = \frac{\partial y_{t+j}}{\partial \epsilon_t} = \frac{\partial y_t}{\partial \epsilon_{t-j}} = \phi^j$$

es idéntica a su función de autocorrelaciones.


Ejemplo 5:  
 $AR(1)$

$$y_t = 0.9y_{t-1} + \epsilon_t$$

Realización




Autocorrelación




$$y_t = -0.9y_{t-1} + \epsilon_t$$

Realización



Autocorrelación





# El proceso AR(p)

- ▶ Es fácil extender el proceso AR(1) para incluir más rezagos.
- ▶ El proceso AR(p) es

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

$$y_t - \phi_1 y_{t-1} - \cdots - \phi_p y_{t-p} = c + \epsilon_t$$

$$(1 - \phi_1 L^1 - \cdots - \phi_p L^p) y_t = c + \epsilon_t$$

$$\Phi(L)y_t = c + \epsilon_t$$

- ▶ El proceso AR(p) es una ecuación en diferencia de orden  $p$ .
- ▶ Esta ecuación es estable si y solo si las raíces del polinomio  $1 - \phi_1 z^1 - \cdots - \phi_p z^p$  están todas **fuera** del círculo unitario.

- ▶ Si el proceso es estable, resolvemos para  $y_t$

$$\begin{aligned}y_t &= \Phi^{-1}(\mathbf{L}) (c + \epsilon_t) \\&= \Phi^{-1}(1)c + \Phi^{-1}(\mathbf{L})\epsilon_t \\&= \frac{c}{1 - \phi_1 - \dots - \phi_p} + \Phi^{-1}(\mathbf{L})\epsilon_t\end{aligned}$$

- ▶ Su valor esperado es

$$\mathbb{E}(y_t) = \frac{c}{1 - \phi_1 - \dots - \phi_p} = \mu$$

- ▶ Similar a lo que obtuvimos para el proceso AR(1), podemos escribir el proceso AR(p) en términos de desviación de la media  $\tilde{y} \equiv y - \mu$ .

$$\tilde{y}_t = \phi_1 \tilde{y}_{t-1} + \dots + \phi_p \tilde{y}_{t-p} + \epsilon_t$$

- Para obtener su varianza y autocovarianzas multiplicamos la expresión anterior por  $\tilde{y}_{t-j}$ , con  $j \geq 0$ , y calculamos el valor esperado

$$\begin{aligned}\mathbb{E}[\tilde{y}_t \tilde{y}_{t-j}] &= \mathbb{E}[\phi_1 \tilde{y}_{t-1} \tilde{y}_{t-j} + \cdots + \phi_p \tilde{y}_{t-p} \tilde{y}_{t-j} + \epsilon_t \tilde{y}_{t-j}] \\ \gamma_j &= \begin{cases} \phi_1 \gamma_1 + \cdots + \phi_p \gamma_p + \sigma^2 & \text{si } j = 0 \\ \phi_1 \gamma_{j-1} + \cdots + \phi_p \gamma_{j-p} & \text{si } j > 0 \end{cases}\end{aligned}$$

- ▶ Si dividimos la última línea entre la varianza  $\gamma_0$  obtenemos las

### Ecuaciones Yule-Walker

$$\rho_j = \phi_1 \rho_{j-1} + \cdots + \phi_p \rho_{j-p}, \text{ con } j > 0$$

- ▶ Esta es la misma ecuación en diferencia que el proceso original, por lo que en principio se puede resolver con los métodos convencionales, una vez que tengamos  $p$  valores iniciales  $\rho_0, \rho_1, \dots, \rho_{p-1}$ .
- ▶ En general, no es tan sencillo obtener despejar los valores de las autocorrelaciones  $\rho_j$ .

- Para obtener la función de impulso respuesta, podríamos partir de la forma

$$y_t = \mu + \Phi^{-1}(L)\epsilon$$

pero esto requiere que obtengamos la forma explícita del polinomio de rezagos

$$\Phi^{-1}(L) = 1 + \psi_1 L + \psi_2 L^2 + \dots$$

- Ahora bien, reconociendo que un proceso AR(p) es una ecuación en diferencia de orden  $p$ , encontramos que

$$\frac{\partial y_{t+j}}{\partial \epsilon_t} = c_1 \lambda_1^j + c_2 \lambda_2^j + \dots + c_p \lambda_p^j$$

donde  $\lambda_j$  son las raíces del polinomio característico  $\lambda^p - \phi_1 \lambda^{p-1} - \dots - \phi_p$  (ver tema 2, p.19-20).

- ▶ Para un proceso AR(p) estacionario, sabemos que todas las raíces  $\lambda_j$  están dentro del círculo unitario.
- ▶ Por ello, a partir de

$$\frac{\partial y_{t+j}}{\partial \epsilon_t} = c_1 \lambda_1^j + c_2 \lambda_2^j + \cdots + c_p \lambda_p^j$$

sabemos que la función de impulso respuesta converge a cero en el largo plazo.

- ▶ La forma de la función depende especialmente del valor  $\lambda_j$  más grande:
  - ▶ Si es positivo, decae geométricamente,
  - ▶ Si es negativo, decae alternando de signo,
  - ▶ Si es complejo, decae oscilando periódicamente (ver tema 2, p.25).

Ejemplo 6:

$$\text{AR}(2): y_t = 0.9y_{t-1} - 0.625y_{t-2} + \epsilon_t$$

$$y_t = 0.9y_{t-1} - 0.625y_{t-2} + \epsilon_t$$

Con las ecuaciones Yule-Walker

$$\phi_1 + \phi_2\rho_1 = \rho_1$$

$$\phi_1\rho_1 + \phi_2 = \rho_2$$

encontramos


$$\rho_1 = \frac{\phi_1}{1 - \phi_2} \approx 0.5538$$

$$\rho_2 = \phi_1\rho_1 + \phi_2 \approx -0.1265$$


Las demás autocorrelaciones las encontramos con

$$\rho_j = 0.9\rho_{j-1} - 0.625\rho_{j-2}$$

Realización



Autocorrelación






La ecuación característica es

$$\lambda^2 - 0.9\lambda + 0.625 = 0$$

con raíces

$$\begin{aligned}\lambda &= 0.45 \pm 0.65i \\ &\approx 0.79 (\cos 0.97 \pm i \sin 0.97)\end{aligned}$$


por lo que el proceso es estacionario.



Usando las fórmulas del tema 2 (pp.19-25), encontramos su función impulso respuesta

$$0.79^j \left[ \cos(0.97j) - \frac{9}{13} \sin(0.97j) \right]$$

la cual converge a cero, oscilando periódicamente conforme  $j \rightarrow \infty$ .




Ejemplo 7:


$AR(1)$  vs  $AR(2)$

- Consideremos estos dos procesos autorregresivos:

$$y_t = 0.9y_{t-1} + \epsilon_t$$



$$y_t = 0.5y_{t-1} + 0.4y_{t-2} + \epsilon_t$$



- Este caso ilustra que es sumamente difícil identificar el orden  $p$  de un proceso  $AR(p)$  a partir de su autocorrelograma.
- Para resolver este problema, a continuación estudiaremos la **autocorrelación parcial**.

# Autocorrelación parcial

- ▶ La autocorrelación parcial mide la correlación **restante** entre  $y_t$  y  $y_{t-k}$  una vez que se han eliminado la influencia de  $y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$ .

$$y_t = \underbrace{a_1^{(k)} y_{t-1} + a_2^{(k)} y_{t-2} + \dots + a_{k-1}^{(k)} y_{t-k+1}}_{\text{"eliminamos" este efecto}} + a_k^{(k)} y_{t-k}$$

- ▶ Es decir, las primeros  $m$  autocorrelaciones parciales vienen de

$$y_t = a_1^{(1)} y_{t-1}$$

$$y_t = a_1^{(2)} y_{t-1} + a_2^{(2)} y_{t-2}$$

$\vdots$

$$y_t = a_1^{(m-1)} y_{t-1} + a_2^{(m-1)} y_{t-2} + \dots + a_{m-1}^{(m-1)} y_{t-m+1}$$

$$y_t = a_1^{(m)} y_{t-1} + a_2^{(m)} y_{t-2} + \dots + a_{m-1}^{(m)} y_{t-m+1} + a_m^{(m)} y_{t-m}$$

- Para encontrar el valor de  $a_k^{(k)}$  basta con resolver

$$\begin{bmatrix} 1 & \rho_1 & \rho_2 & \dots & \rho_{k-1} \\ \rho_1 & 1 & \rho_1 & \dots & \rho_{k-2} \\ \rho_2 & \rho_1 & 1 & \dots & \rho_{k-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \rho_{k-3} & \dots & 1 \end{bmatrix} \begin{bmatrix} a_1^{(k)} \\ a_2^{(k)} \\ a_3^{(k)} \\ \vdots \\ a_k^{(k)} \end{bmatrix} = \begin{bmatrix} \rho_1 \\ \rho_2 \\ \rho_3 \\ \vdots \\ \rho_k \end{bmatrix}$$

- En adelante, denotaremos la  $k$ -ésima correlación parcial por  $\varphi(k) \equiv a_k^{(k)}$

- ▶ Comparando las ecuaciones del proceso AR(p) y de la autocorrelación parcial  $k$ :

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t$$

$$y_t = a_1^{(k)} y_{t-1} + a_2^{(k)} y_{t-2} + \cdots + a_{k-1}^{(k)} y_{t-k+1} + a_k^{(k)} y_{t-k}$$

vemos que


- ▶ si  $k = p$ , entonces  $\varphi_k = \phi_p$
- ▶ si  $k > p$ , entonces  $\varphi_k = 0$
- ▶ si  $k = 1$ , entonces  $\varphi_1 = \rho_1$

Ejemplo 8:


$AR(1)$  vs  $AR(2)$ , con autocorrelación  
parcial

- Consideremos de nuevo estos procesos autorregresivos:

$$y_t = 0.9y_{t-1} + \epsilon_t$$



$$y_t = 0.5y_{t-1} + 0.4y_{t-2} + \epsilon_t$$



- Ahora es muy sencillo identificar el orden  $p$  de los proceso AR.



Para encontrar la segunda autocorrelación parcial, resolvemos

$$\begin{bmatrix} a_1 \\ \varphi_2 \end{bmatrix} = \begin{bmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} \rho_1 \\ \rho_2 \end{bmatrix} = \frac{1}{1 - \rho_1^2} \begin{bmatrix} 1 & -\rho_1 \\ -\rho_1 & 1 \end{bmatrix} \begin{bmatrix} \rho_1 \\ \rho_2 \end{bmatrix}$$

de donde  $\varphi_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$ .

- ▶ Para el proceso AR(1) sabemos que  $\rho_k = \phi^k$ , con lo que comprobamos que  $\varphi_2 = \frac{\phi^2 - \phi^2}{1 - \phi^2} = 0$ .
- ▶ En un ejemplo anterior encontramos que para un proceso AR(2) se cumple

$$\rho_1 = \frac{\phi_1}{1 - \phi_2} = \frac{5}{6} \qquad \rho_2 = \phi_1 \rho_1 + \phi_2 = \frac{49}{60}$$

Al sustituir en la expresión para  $\varphi_2$  comprobamos que

$$\varphi_2 = \frac{\frac{49}{60} - \frac{25}{36}}{1 - \frac{25}{36}} = 0.4 = \phi_2.$$

## 4. Proceso autorregresivo de media móvil

ARMA(p,q)

## Definición: proceso ARMA

Sea  $\{\epsilon_t\}$  un proceso ruido blanco; el proceso estocástico

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

con  $\phi_p, \theta_q \neq 0$  es llamado un proceso ARMA(p,q).

- ▶ ARMA = **A**uto**R**egressive **M**oving **A**verage, (autorregresivo media móvil)
- ▶ Los procesos ARMA son importantes porque todo proceso estacionario puede ser aproximado por un proceso ARMA.

- ▶ Similar a lo que encontramos con los procesos AR(p), si asumimos que es estacionario su media satisface la relación

$$\mu = c + \phi_1\mu + \cdots + \phi_p\mu$$

- ▶ Por lo que el proceso puede escribirse sin el intercepto, si expresamos la variable  $y$  como desviación de su media

$$\tilde{y}_t = \phi_1\tilde{y}_{t-1} + \cdots + \phi_p\tilde{y}_{t-p} + \epsilon_t + \theta_1\epsilon_{t-1} + \cdots + \theta_q\epsilon_{t-q}$$

- ▶ Las fórmulas para la varianza y la autocovarianza se obtienen aplicando las definiciones del caso, pero tienden a ser más complicadas.

# Estabilidad e invertibilidad de un proceso ARMA

El proceso  $\tilde{y}_t = \phi_1 \tilde{y}_{t-1} + \cdots + \phi_p \tilde{y}_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$  puede expresarse en términos de polinomios de rezagos:

$$\begin{aligned}\tilde{y}_t - \phi_1 \tilde{y}_{t-1} - \cdots - \phi_p \tilde{y}_{t-p} &= \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q} \\ (1 - \phi_1 L - \cdots - \phi_p L^p) \tilde{y}_t &= (1 + \theta_1 L + \cdots + \theta_q L^q) \epsilon_t \\ \Phi(L) \tilde{y}_t &= \Theta(L) \epsilon_t\end{aligned}$$

## Estabilidad

Si las raíces del polinomio  $\Phi(z)$  están todas fuera del círculo unitario, el proceso es **estable**.

$$\tilde{y}_t = \Phi(L)^{-1} \Theta(L) \epsilon_t$$

## Invertibilidad

Si las raíces del polinomio  $\Theta(z)$  están todas fuera del círculo unitario, el proceso es **invertible**.

$$\epsilon_t = \Theta(L)^{-1} \Phi(L) \tilde{y}_t$$

# Sobreparametrización de un proceso ARMA

- ▶ Supongamos que tenemos un proceso ARMA(p, q)  
 $\Phi(L)y_t = \Theta(L)\epsilon_t$ , en el cual los polinomios  $\Theta(L)$  tiene una raíz en común. En este caso podemos

$$\begin{aligned}\Phi(L)y_t &= \Theta(L)\epsilon_t \\ (1 - rL)\Phi^*(L)y_t &= (1 - rL)\Theta^*(L)\epsilon_t \\ \Phi^*(L)y_t &= \Theta^*(L)\epsilon_t\end{aligned}$$

- ▶ Es decir, podemos representar el mismo proceso con un modelo ARMA(p-1, q-1).
- ▶ Decimos que:
  - ▶ el modelo ARMA(p,q) está **sobreparametrizado**.
  - ▶ el modelo ARMA(p-1, q-1) es una representación más **parsimoniosa** del proceso generador de datos.

## Ejemplo 9:

# Sobreparametrización



## Consideremos estos dos procesos ARMA

Autocorrelación

Autocorrelación parcial



$$y_t = 1.3y_{t-1} - 0.4y_{t-2} + \epsilon_t + 0.1\epsilon_{t-1} - 0.3\epsilon_{t-2}$$

ARMA(2,2)



$$y_t = 0.8y_{t-1} + \epsilon_t + 0.6\epsilon_{t-1}$$

ARMA(1,1)




¡Sus funciones ACF y PACF son idénticas!




- ▶ Las raíces de los polinomios de rezagos del proceso ARMA(2,2)

Raíces AR



Raíces MA



- ▶ Vemos que ambas tienen a  $z = 0.5$  como una raíz.
- ▶ Al “eliminarla” de ambos polinomios, terminamos con el mismo proceso pero con menos parámetros.
- ▶ Esta representación ARMA(1, 1) es una versión más **parsimoniosa** del mismo proceso.

## 5. Estimación de modelos ARMA

# Introducción (muy breve) al estimador de máxima verosimilitud

- ▶ Sea  $f(y|\theta)$  la función de densidad conjunta de la variable  $Y = [Y_1, \dots, Y_n]$ . Entonces, para una **muestra observada**  $\mathbf{y}$  de esta distribución, la función del vector de parámetros  $\theta$  definida por

$$L(\theta|\mathbf{y}) = f(\mathbf{y}|\theta)$$

se conoce como la **función de verosimilitud**.

- ▶ El **estimador de máxima verosimilitud** es el valor del vector de parámetros  $\theta$  que maximiza la función de verosimilitud

$$\hat{\theta}_{\text{ML}} \equiv \underset{\theta}{\operatorname{argmax}} \underbrace{\mathcal{L}(\theta|\mathbf{y})}_{\ln L[(\theta|\mathbf{y})]}$$

- ▶ Es decir,  $\hat{\theta}_{\text{ML}}$  es el parámetro que hace más plausible haber obtenido la muestra  $\mathbf{y}$  si la verdadera distribución era  $f(y|\theta)$ .

Ejemplo 10:

Estimador máximo verosímil de una  
distribución exponencial

- ▶ Supongamos que tenemos una muestra  $\{x_1, \dots, x_N\}$  de valores tomados de realizaciones independientes de una distribución exponencial con parámetro  $\lambda$
- ▶ La función de densidad de una observación es  $f(x|\lambda) = \lambda e^{-\lambda x}$
- ▶ La función de verosimilitud es la probabilidad conjunta de observar esta muestra:

$$L(\lambda|x_1, \dots, x_N) = \prod_{i=1}^N \lambda e^{-\lambda x_i}$$

o bien, tomando su logaritmo

$$\begin{aligned}\mathcal{L}(\lambda|x_1, \dots, x_N) &= \sum_{i=1}^N [\ln \lambda - \lambda x_i] \\ &= N \ln \lambda - \lambda \sum_{i=1}^N x_i\end{aligned}$$

- Para encontrar el máximo:

$$\frac{\partial \mathcal{L}(\lambda)}{\partial \lambda} = \frac{N}{\lambda} - \sum_{i=1}^N x_i = 0$$

- Por lo tanto, el estimador de máxima verosimilitud es:

$$\hat{\lambda}_{\text{ML}} = \frac{N}{\sum_{i=1}^N x_i} = \frac{1}{\bar{x}}$$

donde  $\bar{x}$  es el promedio simple de los datos.

# Estimación de modelos ARMA

- Pensemos en un proceso ARMA estacionario como una distribución conjunta de  $Y_1, \dots, Y_T$ , donde

$$\mathbb{E}(Y_t) = \mu \qquad \text{Cov}(Y_t, Y_{t-j}) = \gamma_j$$

- Entonces

$$\mathbb{E} \begin{bmatrix} Y_1 \\ \vdots \\ Y_T \end{bmatrix} = \begin{bmatrix} \mu \\ \vdots \\ \mu \end{bmatrix} = \mu$$
$$\text{Var} \begin{bmatrix} Y_1 \\ \vdots \\ Y_T \end{bmatrix} = \gamma_0 \begin{bmatrix} 1 & \rho_1 & \dots & \rho_{T-1} \\ \rho_1 & 1 & \dots & \rho_{T-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{T-1} & \rho_{T-2} & \dots & 1 \end{bmatrix} = \Omega$$

- Supongamos que tenemos una serie de tiempo débilmente estacionaria, con datos generados por el proceso ARMA descrito anteriormente.

$$\mathbf{y} = [y_1, y_2, \dots, y_T]'$$

- Si asumimos que el ruido blanco  $\epsilon_t$  tiene una distribución normal, entonces el proceso ARMA tiene una distribución normal multivariada
- Su función de log-verosimilitud es

$$\mathcal{L}(\theta) = -\frac{T}{2} \ln(2\pi) + \frac{1}{2} \ln |\Omega^{-1}| - \frac{1}{2} (\mathbf{y} - \mu)' \Omega^{-1} (\mathbf{y} - \mu)$$

donde

$$\theta = [c, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q]$$



- ▶ En general, los modelos ARMA se estiman por el método de máxima verosimilitud.
- ▶ Para ello, se igualan a cero las derivadas de la función  $\mathcal{L}(\theta)$  con respecto a cada uno de los parámetros presentes en  $\theta$ .
- ▶ El resultado es un sistema de ecuaciones no lineales que carece de solución cerrada.
- ▶ Por ello, es necesario recurrir a métodos numéricos para resolver estos sistemas de ecuaciones.
- ▶ Por razones de tiempo, no cubrimos estos métodos en este curso. Para más detalles, consulte Greene (2012, capítulo 5) y Miranda y Fackler (2002, capítulos 3 y 4)

- ▶ Para el modelo AR(p)

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \epsilon_t \quad \text{Var}(\epsilon_t) = \sigma^2$$

es posible estimar los parámetros  $c, \phi_1, \dots, \phi_p$  por mínimos cuadrados ordinarios.

- ▶ El resultado es equivalente a un estimador de **máxima verosimilitud condicional**.
- ▶ Se llama así porque los primeros  $p$  valores de la serie se toman como dados.
- ▶ Si la muestra es grande, el resultado es equivalente al estimador de **máxima verosimilitud exacto**.
- ▶ El parámetro  $\sigma^2$  se estima como el promedio de los cuadrados de los residuos de la regresión anterior.

# Ejemplo 11:

## Estimando un modelo AR(3) para la inflación mensual




[bccr.ServicioWeb](#)

---



[ISI-AR3.ipynb](#)

## Veamos la serie histórica y los autocorrelogramas de la inflación mensual subyacente de Costa Rica



Consideremos este proceso AR(3) para modelar la inflación mensual subyacente

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \phi_3 y_{t-3} + \epsilon_t$$

la cual estimamos con datos mensuales (2006m08 a 2020m03, indicador 25725).

	coef	std err	z	P>  z	[0.025	0.975]
<b>const</b>	0.3535	0.104	3.384	0.001	0.149	0.558
<b>ar.L1.isi</b>	0.2534	0.073	3.469	0.001	0.110	0.396
<b>ar.L2.isi</b>	0.1996	0.074	2.679	0.007	0.054	0.346
<b>ar.L3.isi</b>	0.3690	0.073	5.059	0.000	0.226	0.512


- El modelo ajustado es

$$\tilde{y}_t = 0.2534\tilde{y}_{t-1} + 0.1996\tilde{y}_{t-2} + 0.3690\tilde{y}_{t-3} + \epsilon_t$$


$$\tilde{y}_t = y_t - 0.3535$$

$$\epsilon_t \sim N(0, 0.2522^2)$$

Las raíces inversas del polinomio  
 $1 - 0.253L - 0.200L^2 - 0.369L^3$   
están dentro del círculo unitario,  
por lo que el proceso es  
estacionario.



Los residuos de la regresión parecen ruido blanco, excepto por la presencia de un efecto estacional (rezago 12).



## En Stata:

```
. arima isi, arima(3,0,0)
```

```
(setting optimization to BHHH)
```

```
Iteration 0: log likelihood = -7.3405352
```

```
Iteration 1: log likelihood = -7.3208124
```

```
Iteration 2: log likelihood = -7.3199769
```

```
Iteration 3: log likelihood = -7.3197271
```

```
Iteration 4: log likelihood = -7.3196206
```


```
(switching optimization to BFGS)
```

```
Iteration 5: log likelihood = -7.3195774
```

```
Iteration 6: log likelihood = -7.3195452
```

```
Iteration 7: log likelihood = -7.3195446
```

Iteraciones del  
método numérico



```
ARIMA regression
```

```
Sample: 2006m8 - 2020m3
```

```
Number of obs = 164
```

```
Wald chi2(3) = 202.08
```

```
Prob > chi2 = 0.0000
```

```
Log likelihood = -7.319545
```

	isi	OPG		z	P> z	[95% Conf. Interval]	
		Coef.	Std. Err.				
<b>isi</b>							
	_cons	.3534968	.1181878	2.99	0.003	.121853	.5851406
<b>ARMA</b>							
	ar						
	L1.	.2533589	.0724494	3.50	0.000	.1113607	.3953571
	L2.	.1995733	.0514003	3.88	0.000	.0988305	.3003161
	L3.	.3689968	.0712193	5.18	0.000	.2294095	.5085841
	/sigma	.2521808	.0103002	24.48	0.000	.2319929	.2723688




- ▶ En la estimación de máxima verosimilitud de un modelo ARMA( $p, q$ ) hay un supuesto implícito: que sabemos el orden del proceso, es decir, que sabemos el número “correcto” de rezagos  $p, q$
- ▶ En la práctica, esto rara vez sucede.
- ▶ Tenemos una disyuntiva: Entre más rezagos incluyamos
  - ▶ “mejor” será el ajuste del modelo a los datos.
  - ▶ “peor” se vuelve la precisión de los parámetros que se estiman.
- ▶ La metodología de Box-Jenkins sugiere buscar modelos **parsimoniosos**.

- ▶ La parsimonia (usar tan pocos parámetros como sea necesario) tiene sus beneficios a la hora de hacer pronósticos.
- ▶ Muchos modelos estructurales complejos tienen un ajuste muy alto a la muestra en que se estiman, pero hacen pronósticos muy pobres fuera de la muestra.
- ▶ Sorprendentemente, modelos ARMA univariados sencillos pueden hacer mejores pronósticos.
- ▶ La idea es que entre más parámetros haya que estimar, más posibilidad hay de hacerlo mal.

El enfoque para pronosticar de Box-Jenkins consiste de cuatro etapas:

1. Transformar los datos (de ser necesario) para que el supuesto de estacionariedad sea razonable.
2. Adivinar valores pequeños de  $p$  y  $q$  para un modelo ARMA( $p,q$ ) que pueda describir la serie transformada.
3. Estimar los parámetros de  $\phi(L)$  y  $\theta(L)$ .
4. Realizar análisis de diagnóstico para confirmar que el modelo es consistente con los datos observados.

# Distinguiendo los procesos $AR(p)$ de los $MA(q)$



- ▶ El autocorrelograma y el autocorrelograma parcial ayudan a reconocer series  $\text{ARMA}(p,0)$  y  $\text{ARMA}(0,q)$ , pero no series  $\text{ARMA}(p,q)$  con  $pq \neq 0$ .
- ▶ Para esto, recurrimos a **criterios de selección**.
- ▶ Estos criterios tratan de resolver la disyuntiva de que a mayores valores de  $p, q$ , “mejor” será el ajuste pero “peor” la precisión de la estimación.
- ▶ Los criterios más usuales son el de Akaike (Akaike) y el de Bayes (BIC).

- ▶ Sean  $\mathcal{L}$  el máximo de la función log-verosimilitud,  $T$  el número de observaciones, y  $K = p + q + 2$  el número de parámetros estimado.
- ▶ Entonces

#### Criterio de información de Akaike

$$\text{AIC} = \underbrace{-2\mathcal{L}}_{\text{"desajuste"}} + \underbrace{2K}_{\text{penalización}}$$

#### Criterio de información de Bayes

$$\text{BIC} = \underbrace{-2\mathcal{L}}_{\text{"desajuste"}} + \underbrace{\ln(T)K}_{\text{penalización}}$$

- ▶ Se escoge la combinación  $p, q$  que minimiza el criterio de información.
- ▶ En la práctica, en ocasiones AIC y BIC escogen modelos distintos.

## Ejemplo 12:

# Seleccionando $p$ , $q$ para un modelo ARMA de inflación



[bccr.ServicioWeb](#)

---



[ISI-AR3.ipynb](#)

En Stata, para el modelo AR(3) que estimamos en el ejemplo anterior:

```
. estat ic
```

Akaike's information criterion and Bayesian information criterion

Model	Obs	ll(null)	ll(model)	df	AIC	BIC
.	T= 164	L= -7.319545	K= 5	24.63909	40.13842	

Calculamos los criterios de información:

$$\begin{aligned} \text{AIC} &= -2\mathcal{L} + 2K \\ &= -2 \times -7.3195 + 2 \times 5 = 24.63909 \end{aligned}$$

$$\begin{aligned} \text{BIC} &= -2\mathcal{L} + \ln(T)K \\ &= -2 \times -7.3195 + \ln(164) \times 5 = 40.13842 \end{aligned}$$



- ▶ Si calculamos los dos criterios para una combinación de valores  $p, q$  obtenemos

AIC			
	q=0	q=1	q=2
p=0	128.02	89.62	83.77
p=1	64.31	30.74	31.92
p=2	46.27	32.21	34.44
p=3	24.64	26.51	28.32
p=4	26.50	28.43	25.10

BIC			
	q=0	q=1	q=2
p=0	134.22	98.92	96.17
p=1	73.61	43.14	47.42
p=2	58.67	47.71	53.04
p=3	40.14	45.11	50.02
p=4	45.10	50.13	49.90

- ▶ Esto nos indica que la serie de tiempo debe modelarse como un proceso AR(3).

## 6. Pronósticos con modelos ARMA

- ▶ Sea  $y_{t+j|t}^*$  un pronóstico de  $y_{t+j}$  pasado en datos observados hasta  $t$ .
- ▶ Definimos el “mejor” pronóstico de este tipo como aquel que minimiza el **error cuadrático medio**

$$\text{MSE} \left( y_{t+j|t}^* \right) \equiv \mathbb{E} \left( y_{t+j} - y_{t+j|t}^* \right)^2$$

- ▶ Aunque no lo probamos aquí, resulta que el pronóstico con el menor error cuadrático medio es la esperanza de  $y_{t+j}$  condicional en los datos hasta  $t$ :

$$y_{t+j|t}^* = \mathbb{E} \left( y_{t+j} | y_t, y_{t-1}, \dots \right) \equiv \mathbb{E}_t \left( y_{t+j} \right)$$

# Pronosticando valores puntuales de la serie

- ▶ Es muy sencillo obtener de manera recursiva estos pronósticos para los modelos ARMA, siguiendo estos 3 pasos:
  1. Se escribe la ecuación ARMA de manera que  $y_t$  quede a la izquierda y todos los otros términos a la derecha.
  2. Se sustituye el índice  $t$  por  $T + h$ .
  3. En el lado derecho de la ecuación, se sustituyen:
    - ▶ observaciones futuras con sus pronósticos,
    - ▶ errores futuros con cero,
    - ▶ errores pasados con sus respectivos residuos.
- ▶ Empezando con  $h = 1$ , se repiten los pasos 2 y 3 para valores  $h = 2, 3, \dots$  hasta que todos los pronósticos hayan sido calculados.

Para ilustrar el procedimiento, consideremos este proceso  
ARMA(1,2)

$$(1 - \phi L)\tilde{y}_t = (1 + \theta_1 L + \theta_2 L^2)\epsilon_t$$

► Paso 1:  $\tilde{y}_t = \phi\tilde{y}_{t-1} + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2}$

► Para  $h = 1$ :  $\tilde{y}_{T+1} = \phi\tilde{y}_T + \epsilon_{T+1} + \theta_1\epsilon_T + \theta_2\epsilon_{T-1}$   
 $\tilde{y}_{T+1|T}^* = \phi\tilde{y}_T + \theta_1\hat{\epsilon}_T + \theta_2\hat{\epsilon}_{T-1}$

► Para  $h = 2$ :  $\tilde{y}_{T+2} = \phi\tilde{y}_{T+1} + \epsilon_{T+2} + \theta_1\epsilon_{T+1} + \theta_2\epsilon_T$   
 $y_{T+2|T}^* = \phi\tilde{y}_{T+1|T}^* + \theta_2\hat{\epsilon}_T$

► Para  $h = 3$ :  $\tilde{y}_{T+3} = \phi\tilde{y}_{T+2} + \epsilon_{T+3} + \theta_1\epsilon_{T+2} + \theta_2\epsilon_{T+1}$   
 $y_{T+3|T}^* = \phi\tilde{y}_{T+2|T}^*$

- ▶ Es fácil comprobar que, siguiendo este procedimiento, una vez que  $h > p$ ,  $h > q$  la ecuación de pronóstico será

$$\tilde{y}_{T+h}^* = \phi_1 \tilde{y}_{T+h-1}^* + \cdots + \phi_p \tilde{y}_{T+h-p}^*$$

- ▶ Esto es una ecuación en diferencia de orden  $p$ , de la cual sabemos que sus raíces están dentro del círculo unitario.
- ▶ Por ello

$$\lim_{h \rightarrow \infty} \tilde{y}_{T+h}^* = 0 \quad \text{es decir} \quad \lim_{h \rightarrow \infty} y_{T+h}^* = \mu$$

- ▶ Esto nos dice que, para valores grandes de  $h$ , el pronóstico es simplemente la media del proceso.

# Cuantificando la incertidumbre de los pronósticos puntuales

- ▶ Para saber qué tan precisos esperamos que sean estos pronósticos, necesitamos cuantificar su error cuadrático medio

$$\begin{aligned}\text{MSE} \left( y_{t+j|t}^* \right) &\equiv \mathbb{E} \left( y_{t+j} - y_{t+j|t}^* \right)^2 \\ &= \mathbb{E} \left( y_{t+j} - \mathbb{E}_t \left( y_{t+j} \right) \right)^2 \\ &= \text{Var}_t \left( y_{t+j} \right)\end{aligned}$$

- ▶ Es decir, necesitamos cuantificar la varianza de  $y_{t+j}$  condicional en los datos disponibles en  $t$ .
- ▶ Por razones de tiempo, no vamos a desarrollar estas fórmulas durante este curso.

## Ejemplo 13:

# Pronosticando la inflación




`bccr.ServicioWeb`

---



`ISI-AR3.ipynb`





# ¿Qué podría salir mal?


- ▶ En todas las fórmulas que hemos elaborado para los pronósticos hasta ahora, está implícito que conocemos los verdaderos valores de los parámetros.
- ▶ En la práctica, esos parámetros son estimados a partir de los datos.
- ▶ Tomemos por ejemplo un proceso AR(1):

$$y_{t+1} = \phi y_t + \epsilon_{t+1} \quad (\text{valor verdadero})$$

$$y_{t+1|t}^* = \hat{\phi} y_t \quad (\text{pronóstico})$$

---

$$\underbrace{y_{t+1} - y_{t+1|t}^*}_{\text{error de pronóstico}} = \underbrace{(\phi - \hat{\phi})}_{\text{"sesgo"}} y_t + \underbrace{\epsilon_{t+1}}_{\text{innovación}}$$

-  Beckett, Sean (2013). *Introduction to Time Series Using Stata*. 1ª ed. Stata Press. ISBN: 978-1-59718-132-7.
-  Enders, Walter (2015). *Applied Econometric Time Series*. 4ª ed. Wiley. ISBN: 978-1-118-80856-6.
-  Greene, William H. (2012). *Econometric Analysis*. 7ª ed. Prentice Hall. ISBN: 978-0-13-139538-1.
-  Hamilton, James M. (1994). *Time Series Analysis*. Princeton University Press. ISBN: 0-691-04289-6.
-  Kirchgässner, Gebhard, Jürgen Wolters y Uwe Hassler (2013). *Introduction to Modern Time Series Analysis*. 2ª ed. Springer. ISBN: 978-3-642-33435-1.
-  Miranda, Mario J. y Paul L. Fackler (2002). *Applied Computational Economics and Finance*. MIT Press. ISBN: 0-262-13420-9.